Alunos: Ozaeltton Matheus da Silva Medeiros (20231038060022) e Kauê Adriano dos Santos Dantas (20241038060007)

Classificação de dados - vgsales

Código-fonte: Árvore de decisão e Naive Bayes. Utilizamos GridSearchCV para encontrar parâmetros.

```
    import numpy as np
    import pandas as pd
    import matplotlib.pyplot as plt
    from sklearn.compose import ColumnTransformer
    from sklearn.pipeline import Pipeline
    from sklearn.preprocessing import StandardScaler, OneHotEncoder
    from sklearn.impute import SimpleImputer
    from sklearn.decomposition import PCA
    from sklearn.cluster import KMeans, AgglomerativeClustering
    from sklearn.mixture import GaussianMixture
    from sklearn.metrics import (silhouette_score,
davies_bouldin_score,
                                 adjusted_rand_score,
normalized_mutual_info_score,
                                 homogeneity_completeness_v_measure)
    from sklearn.model_selection import GridSearchCV, StratifiedKFold
    from sklearn.model_selection import train_test_split
    from sklearn.tree import DecisionTreeClassifier, plot_tree
    from sklearn.metrics import (accuracy_score, classification_report,
    confusion_matrix, f1_score)
    from sklearn.model_selection import train_test_split
    from sklearn.model_selection import cross_val_score
    from sklearn.naive_bayes import GaussianNB


    # Parâmetros da variável-alvo
    # Participação do Japão nas vendas (NA + EU + JP) de cada jogo:
    # abaixo de LIMIAR_OCIDENTE -> "Ocidente"
    # acima de LIMIAR_ORIENTE   -> "Oriente"
    # entre os dois             -> "Equilibrado"
    LIMIAR_OCIDENTE = 0.10
    LIMIAR_ORIENTE = 0.50

    # Parâmetros do agrupamento
    SEED = 42
```

```
    N_COMPONENTES_PCA = 10        # componentes mantidas após o PCA
    K_MIN, K_MAX = 2, 8               # intervalo de k testado para
escolher o nº de grupos
    N_AMOSTRA_HIERARQUICO = 5000   # o aglomerativo guarda a matriz de
distâncias (memória
                                  # cresce com n²), por isso roda em uma
amostra do dataset

    data = pd.read_csv('./vgsales.csv')

    print("-" * 20 + "Primeiras linhas do dataset" + "-" * 20)
    print(data.head())

    print("-" * 20 + "Últimas linhas do dataset" + "-" * 20)
    print(data.tail())

    print("-" * 20 + "Formato do dataset" + "-" * 20)
    print(data.shape)  # esperado: cerca de 16.598 linhas e 11 colunas

    print("-" * 20 + "Tipos das colunas" + "-" * 20)
    print(data.dtypes)

    # Valores nulos por coluna (o pandas já lê "N/A" do CSV como nulo).
    # Publisher e Year possuem nulos; as colunas de vendas não.
    print("-" * 20 + "Valores nulos por coluna" + "-" * 20)
    print(data.isnull().sum())

    # Linhas duplicadas
    print("-" * 20 + "Linhas duplicadas" + "-" * 20)
    print(data.duplicated().sum())

    # Os valores 0 nas colunas de vendas têm significado para a análise
(o jogo
    # vendeu menos de 10 mil cópias na região, no arredondamento do
dataset),
    # portanto não são apagados nem substituídos.

    # Exclusão de colunas desnecessárias para a análise:
    # Rank: é calculado a partir de Global_Sales, que contém as vendas
das
    # regiões usadas para criar o alvo (vazamento de informação).
    # Global_Sales: soma das regiões, incluindo as que usamos para o
alvo.
```

```
    # Other_Sales: fora do recorte Ocidente x Oriente.
    # Name: identificador (milhares de valores únicos), sem poder de
generalização.
    # A coluna Year é MANTIDA: plataformas e gêneros mudam muito com a
época,
    # e o ano ajuda a separar o efeito temporal do efeito cultural.
    data    =    data.drop(columns=['Rank',    'Name',    'Other_Sales',
'Global_Sales'])

    # Ocidente = América do Norte + Europa; Oriente = Japão.
    data["West_Sales"] = data["NA_Sales"] + data["EU_Sales"]
    data["East_Sales"] = data["JP_Sales"]
    total_regioes = data["West_Sales"] + data["East_Sales"]

    # Jogos sem vendas nas três regiões (vendas apenas em Other_Sales)
não têm
    # como receber uma classe e são removidos.
    sem_vendas = total_regioes == 0
    print("-" * 20 + "Jogos removidos (sem vendas em NA, EU e JP)" +
"-" * 20)
    print(int(sem_vendas.sum()))
    data = data[~sem_vendas].copy()
    total_regioes = total_regioes[~sem_vendas]

    # Comparar West_Sales com East_Sales diretamente favoreceria o
Ocidente por
    # construção (duas regiões somadas contra uma). Por isso o alvo usa
a
    # participação do Japão nas vendas de cada jogo: mede se o jogo
performa de
    # forma relativamente melhor no Oriente, independentemente do
tamanho do mercado.
    data["Participacao_Oriente"] = data["East_Sales"] / total_regioes

    # Construção da variável-alvo (Mercado) a partir da participação do
Japão nas vendas.
    # Indica qual mercado o jogo vende mais: Ocidente, Oriente ou
Equilibrado.
    data["Mercado"] = np.select(
      [
          data["Participacao_Oriente"] < LIMIAR_OCIDENTE,
          data["Participacao_Oriente"] > LIMIAR_ORIENTE,
      ],
```

```
      ["Ocidente", "Oriente"],
      default="Equilibrado",
    )

    print("-" * 20 + "Distribuição da variável-alvo (Mercado)" + "-" *
20)
    print(data["Mercado"].value_counts())
    print(data["Mercado"].value_counts(normalize=True).round(3))
    #  Classes  desbalanceadas:  nas  próximas  etapas  usar  validação
cruzada
    # estratificada e métricas como F1 macro / acurácia balanceada.

    #  As  colunas  de  vendas  e  derivadas  saem  das  características,
evitando vazamento de informação.
    colunas_vendas = ["NA_Sales", "EU_Sales", "JP_Sales",
                      "West_Sales", "East_Sales", "Participacao_Oriente"]

    y = data["Mercado"]
    X = data.drop(columns=colunas_vendas + ["Mercado"])

    colunas_categoricas = ['Platform', 'Genre', 'Publisher']
    colunas_numericas = ['Year']

    # Pré-processamento abaixo
    #  Categóricas:  nulos  viram  "Unknown";  categorias  raras  (poucos
jogos, comum em
    #  Publisher)  são  agrupadas  em  uma  categoria  "infrequente"  para
evitar centenas
    # de colunas quase vazias.
    pipeline_categorico = Pipeline([
                    ('imputer',       SimpleImputer(strategy='constant',
fill_value='Unknown')),
          ('onehot',  OneHotEncoder(handle_unknown='infrequent_if_exist',
min_frequency=10, sparse_output=False)),
    ])

    # Numéricas: nulos viram a mediana; depois padronização.
    pipeline_numerico = Pipeline([
      ('imputer', SimpleImputer(strategy='median')),
      ('scaler', StandardScaler()),
    ])
```

```
    # Este "preprocessor" pode ser usado dentro de um Pipeline com o classificador
    # nas próximas etapas, para ser reajustado a cada dobra da validação cruzada.
    preprocessor = ColumnTransformer(
      transformers=[
          ('cat', pipeline_categorico, colunas_categoricas),
          ('num', pipeline_numerico, colunas_numericas),
      ]
    )

    # Agrupamento (clusterização)
    # O agrupamento é não supervisionado: usa todos os jogos (sem divisão treino/teste)
    # e a coluna-alvo (Mercado) NÃO participa da formação dos grupos. Ela é usada
    # apenas no final, para comparar os grupos descobertos com a rotulação existente.
    X_proc = preprocessor.fit_transform(X)
    if hasattr(X_proc, "toarray"):  # o one-hot pode devolver matriz esparsa
      X_proc = X_proc.toarray()

    print("-" * 20 + "Resultado do pré-processamento" + "-" * 20)
    print("Dimensão:", X_proc.shape)

    # O PCA reduz as colunas geradas pelo one-hot, deixando as distâncias mais estáveis
    pca = PCA(n_components=min(N_COMPONENTES_PCA, X_proc.shape[1]), random_state=SEED)
    X_pca = pca.fit_transform(X_proc)
    print(f"Variância explicada pelo PCA: {pca.explained_variance_ratio_.sum():.2%}")

    # Escolha do número de grupos (K-Means): método do cotovelo e silhouette
    inercias = {}
    silhouettes = {}
    for k in range(K_MIN, K_MAX + 1):
        kmeans = KMeans(n_clusters=k, n_init=10, random_state=SEED).fit(X_pca)
      inercias[k] = kmeans.inertia_
      silhouettes[k] = silhouette_score(X_pca, kmeans.labels_,
```

```
                                                    sample_size=5000,
random_state=SEED)

    k_silhouette = max(silhouettes, key=silhouettes.get)
    k_alvo = y.nunique()   # nº de grupos igual ao nº de classes da
variável-alvo

    print("-" * 20 + "Escolha do número de grupos" + "-" * 20)
    print("Silhouette por k:", {k: round(v, 3) for k, v in
silhouettes.items()})
    print("k com maior silhouette:", k_silhouette)
    print("k igual ao nº de classes de Mercado:", k_alvo)

    fig, eixos = plt.subplots(1, 2, figsize=(10, 4))
    eixos[0].plot(list(inercias.keys()),       list(inercias.values()),
marker='o')
    eixos[0].set_title("Método do cotovelo (K-Means)")
    eixos[0].set_xlabel("k")
    eixos[0].set_ylabel("Inércia")
    eixos[1].plot(list(silhouettes.keys()), list(silhouettes.values()),
marker='o', color='tab:orange')
    eixos[1].set_title("Silhouette (K-Means)")
    eixos[1].set_xlabel("k")
    eixos[1].set_ylabel("Silhouette")
    plt.tight_layout()
    plt.savefig("escolha_k.png", dpi=150)
    plt.show()

    # Amostra para o agrupamento hierárquico (os demais algoritmos usam
todos os jogos)
    todos = np.arange(len(X_pca))
    amostra = np.sort(np.random.RandomState(SEED).choice(
            todos,    size=min(N_AMOSTRA_HIERARQUICO,    len(todos)),
replace=False))

    def aplicar_algoritmos(k):
        """Executa os três algoritmos com k grupos. Devolve {nome:
(índices usados, grupos)}."""
      return {
                  "K-Means": (todos, KMeans(n_clusters=k, n_init=10,
random_state=SEED).fit_predict(X_pca)),
          "Aglomerativo (Ward)": (amostra, AgglomerativeClustering(
```

```
                                                        n_clusters=k,
linkage="ward").fit_predict(X_pca[amostra])),
                    "GMM":   (todos,   GaussianMixture(n_components=k,
covariance_type="full",
                                                    reg_covar=1e-4,
random_state=SEED).fit_predict(X_pca)),
      }

    def pureza(grupos, rotulo):
       """Fração de jogos que pertencem à classe majoritária do seu
grupo."""
      tabela = pd.crosstab(grupos, rotulo)
      return tabela.max(axis=1).sum() / tabela.values.sum()

    def avaliar(nome, k, indices, grupos):
        """Métricas  internas  (qualidade  dos  grupos)  e  externas
(concordância com Mercado)."""
      rotulo = y.iloc[indices]
                homogeneidade,      completude,      v_measure      =
homogeneity_completeness_v_measure(rotulo, grupos)
      return {
          "Algoritmo": nome,
          "k": k,
          "Jogos": len(indices),
          "Silhouette": silhouette_score(X_pca[indices], grupos,
                                                sample_size=5000,
random_state=SEED),
              "Davies-Bouldin":  davies_bouldin_score(X_pca[indices],
grupos),
          "ARI": adjusted_rand_score(rotulo, grupos),
          "NMI": normalized_mutual_info_score(rotulo, grupos),
          "Homogeneidade": homogeneidade,
          "Completude": completude,
          "V-measure": v_measure,
          "Pureza": pureza(grupos, rotulo),
      }

    resultados = []
    grupos_por_k = {}
    for k in sorted({k_alvo, k_silhouette}):
      grupos_por_k[k] = aplicar_algoritmos(k)
      for nome, (indices, grupos) in grupos_por_k[k].items():
          resultados.append(avaliar(nome, k, indices, grupos))
```

```
    comparativo = pd.DataFrame(resultados).round(3)

    # Referência para a pureza: sempre prever a classe majoritária de
Mercado
    print("-" * 20 + "Pureza de referência (classe majoritária de
Mercado)" + "-" * 20)
    print(round(y.value_counts(normalize=True).max(), 3))

    pd.set_option("display.width", 200)
    pd.set_option("display.max_columns", None)
    print("-" * 20 + "Comparativo entre os algoritmos" + "-" * 20)
    print(comparativo.to_string(index=False))

    # Comparação detalhada dos grupos com a rotulação existente (k = n°
de classes)
    for nome, (indices, grupos) in grupos_por_k[k_alvo].items():
      print("-" * 20 + f"{nome}: grupos x Mercado" + "-" * 20)
                print(pd.crosstab(pd.Series(grupos,      name="Grupo"),
y.iloc[indices].values,
                        rownames=["Grupo"], colnames=["Mercado"]))

       # Perfil de cada grupo (vendas em milhões, participação do Japão
e ano médio)
          perfil   =   data.iloc[indices][["West_Sales",   "East_Sales",
"Participacao_Oriente", "Year"]]
      perfil = perfil.groupby(grupos).mean().round(3)
      perfil["Jogos"] = pd.Series(grupos).value_counts().sort_index()
      print("Perfil médio de cada grupo:")
      print(perfil)

      # Categoria mais frequente de cada grupo
      for coluna in colunas_categoricas:
          print(f"{coluna} mais frequente por grupo:")
          print(X.iloc[indices][coluna].groupby(grupos).agg(
              lambda s: s.value_counts().index[0]))

    # Visualização: projeção nas duas primeiras componentes do PCA
    paineis = [("Mercado (rotulação existente)", y.values, todos)]
    for nome, (indices, grupos) in grupos_por_k[k_alvo].items():
      paineis.append((nome, grupos, indices))

    fig, eixos = plt.subplots(2, 2, figsize=(12, 9))
```

```
    for eixo, (titulo, rotulos, indices) in zip(eixos.ravel(),
paineis):
      categorias = pd.Series(rotulos).astype(str)
      for categoria in sorted(categorias.unique()):
          mascara = (categorias == categoria).values
                          eixo.scatter(X_pca[indices][mascara,    0],
X_pca[indices][mascara, 1],
                       s=8, alpha=0.5, label=categoria)
      eixo.set_title(titulo)
      eixo.set_xlabel("PC1")
      eixo.set_ylabel("PC2")
      eixo.legend(fontsize=8)
    plt.tight_layout()
    plt.savefig("comparacao_grupos.png", dpi=150)
    plt.show()

    # Divisão treino/teste
    X_treino, X_teste, y_treino, y_teste = train_test_split(
       X, y, test_size=0.25, stratify=y, random_state=42
    )

    cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

    # Árvore de decisão
    # O pré-processamento fica dentro do Pipeline: aprende só com o
treino
    # (e só com as dobras de treino durante a validação cruzada).
    modelo_arvore = Pipeline(steps=[
       ("preprocessamento", preprocessor),
       ("arvore", DecisionTreeClassifier(
           criterion="gini",
           max_depth=4,
           min_samples_leaf=30,
           class_weight="balanced",
           random_state=42
       ))
    ])

    modelo_arvore.fit(X_treino, y_treino)
    y_pred = modelo_arvore.predict(X_teste)

    print("-" * 20 + "Árvore inicial (max_depth=4)" + "-" * 20)
    print("Acurácia:", accuracy_score(y_teste, y_pred))
```

```
    print("\nRelatório de classificação:")
    print(classification_report(y_teste, y_pred, zero_division=0))
    print("Matriz de confusão:")
    print(confusion_matrix(y_teste,                                y_pred,
labels=modelo_arvore.classes_))

    # Visualização da árvore inicial
    # Os nomes das features vêm do pré-processador.
    arvore = modelo_arvore.named_steps["arvore"]
    nomes_features                                                      =
modelo_arvore.named_steps["preprocessamento"].get_feature_names_out()

    plt.figure(figsize=(24, 12))
    plot_tree(
       arvore,
       feature_names=nomes_features,
         class_names=list(arvore.classes_),    # Equilibrado, Ocidente,
Oriente
       filled=True,
       rounded=True,
       proportion=True,
       impurity=False
    )
    plt.title("Árvore de decisão para previsão do mercado (Mercado)")
    plt.savefig("arvore_decisao.png", dpi=150)
    plt.show()

    # Grid ampliado:
    # - min_samples_leaf inclui 3 e 5 (o melhor anterior foi 10, o
menor valor testado)
    # - class_weight inclui None, para comparar a precisão da classe
Equilibrado
    parametros_arvore = {
       "arvore__max_depth": [3, 4, 6, 8, 10, None],
       "arvore__min_samples_leaf": [3, 5, 10, 30, 50],
       "arvore__criterion": ["gini", "entropy"],
       "arvore__class_weight": ["balanced", None],
    }

    busca_arvore = GridSearchCV(
       estimator=modelo_arvore,
       param_grid=parametros_arvore,
       scoring="f1_macro",
```

```
        cv=cv,
        n_jobs=-1
    )
    busca_arvore.fit(X_treino, y_treino)

    print("-" * 20 + "Árvore: busca de hiperparâmetros" + "-" * 20)
    print("Melhores parâmetros:", busca_arvore.best_params_)
    print("Melhor F1 macro na validação cruzada:",
round(busca_arvore.best_score_, 4))

    # O melhor modelo já vem treinado com todo o treino; o teste só é
usado aqui
    melhor_arvore = busca_arvore.best_estimator_
    y_pred_arvore = melhor_arvore.predict(X_teste)

    print("Acurácia no teste:", accuracy_score(y_teste, y_pred_arvore))
    print(classification_report(y_teste, y_pred_arvore,
zero_division=0))
    print(confusion_matrix(y_teste, y_pred_arvore,
labels=melhor_arvore.classes_))

    # Algoritmo Naive Bayes
    modelo_nb = Pipeline(steps=[
        ("preprocessamento", preprocessor),
        ("nb", GaussianNB())
    ])

    # Grid ampliado: o melhor anterior (0.1) era o maior valor testado
    parametros_nb = {
        "nb__var_smoothing": [1e-9, 1e-5, 1e-3, 1e-1, 0.3, 0.5, 1, 2, 5]
    }

    busca_nb = GridSearchCV(
        estimator=modelo_nb,
        param_grid=parametros_nb,
        scoring="f1_macro",
        cv=cv,
        n_jobs=-1
    )
    busca_nb.fit(X_treino, y_treino)

    print("-" * 20 + "Naive Bayes: busca de hiperparâmetros" + "-" *
20)
```

```
    print("Melhores parâmetros:", busca_nb.best_params_)
    print("Melhor F1 macro na validação cruzada:",
round(busca_nb.best_score_, 4))

    melhor_nb = busca_nb.best_estimator_
    y_pred_nb = melhor_nb.predict(X_teste)

    print("Acurácia no teste:", accuracy_score(y_teste, y_pred_nb))
    print(classification_report(y_teste, y_pred_nb, zero_division=0))
    print(confusion_matrix(y_teste, y_pred_nb,
labels=melhor_nb.classes_))

    # Validação cruzada
    # O GridSearchCV roda DENTRO de cada dobra externa: os
hiperparâmetros são
    # escolhidos só com o treino da dobra, e a avaliação usa a dobra de
teste,
    # que não participou da escolha. Usa-se X, y completos (sem o split
acima).
    cv_interna = StratifiedKFold(n_splits=3, shuffle=True,
random_state=42)
    cv_externa = StratifiedKFold(n_splits=5, shuffle=True,
random_state=7)

    busca_arvore_interna = GridSearchCV(
            modelo_arvore, parametros_arvore, scoring="f1_macro",
cv=cv_interna, n_jobs=-1
    )
    busca_nb_interna = GridSearchCV(
        modelo_nb, parametros_nb, scoring="f1_macro", cv=cv_interna,
n_jobs=-1
    )

    scores_arvore = cross_val_score(busca_arvore_interna, X, y,
cv=cv_externa, scoring="f1_macro")
    scores_nb = cross_val_score(busca_nb_interna, X, y, cv=cv_externa,
scoring="f1_macro")

    print("-" * 20 + "Validação cruzada aninhada (F1 macro)" + "-" *
20)
    print("Árvore por dobra:", scores_arvore.round(4),
            "| Média:", round(scores_arvore.mean(), 4), "| DP:",
round(scores_arvore.std(), 4))
```

```
    print("Naive Bayes por dobra:", scores_nb.round(4),
                "|  Média:",  round(scores_nb.mean(),  4),  "|  DP:",
round(scores_nb.std(), 4))

    # Tabela comparativa final
    comparacao = pd.DataFrame({
       "Modelo": ["Árvore de decisão", "Naive Bayes"],
             "F1  macro  (grid,  CV)":  [busca_arvore.best_score_,
busca_nb.best_score_],
              "F1  macro  (CV  aninhada)":  [scores_arvore.mean(),
scores_nb.mean()],
       "Acurácia (teste)": [
           accuracy_score(y_teste, y_pred_arvore),
           accuracy_score(y_teste, y_pred_nb),
       ],
       "F1 macro (teste)": [
           f1_score(y_teste, y_pred_arvore, average="macro"),
           f1_score(y_teste, y_pred_nb, average="macro"),
       ],
    }).round(4)

    print("-" * 20 + "Comparativo final" + "-" * 20)
    print(comparacao.to_string(index=False))
```